

# Segmentación de Imágenes

Profesora del curso:  
Diana Patricia Tobón Vallejo, PhD

Tratamiento de Señales III  
Facultad de Ingeniería  
Universidad de Antioquia



2024-2

*Material elaborado por: Hernán Felipe García Arias*


# Contenido

- 1 Definiendo la segmentación
- 2 Segmentación basada en información de vecindad
- 3 Segmentación utilizando probabilidades
- 4 Segmentación multi-clase

# Segmentación

La segmentación es el proceso para convertir los píxeles de una imagen en un número limitado (pequeño) de clases según:

- ❑ El histograma de la imagen
- ❑ Conocimiento a priori de las estadísticas de la imagen
- ❑ Información del vecindario de la imagen



# Palabras Claves

## Clasificación

Identificar regiones basado en propiedades características

- ❑ Intensidad
- ❑ Color
- ❑ Textura

## Métodos no-supervisados (Unsupervised)

El algoritmo puede encontrar regiones sin la interacción del humano

## Etiquetado

Identificar ítems individuales, a menudo requiere una imagen clasificada como entrada


## Métodos supervisados (Supervised)

El algoritmo necesita la intervención del humano, como punto de inicio en el procesamiento

# Umbralizado (Thresholding)

Umbral de una imagen: compare el valor de pixel con un valor constante


$$g(x) = \begin{cases} 1 & f(x) \geq \gamma \\ 0 & \text{otherwise} \end{cases} \quad \forall x \in \Omega \quad (1)$$






La pregunta ahora es: ¿Cual valor de umbral elegir? ... Sezgin and Sankur (2004) [1].

# Problemas en la segmentación




Ideally



Noise




Unsharpness






# Problemas en la segmentación




Ideally



Artifacts



Gradients






# Segmentación basada en histograma

- ❑ Utiliza la información proporcionada por el histograma para encontrar un valor de umbral



# Umbral de Otsu

Otsu introdujo un algoritmo clásico para encontrar un umbral.



# Algoritmo de umbralización de Otsu

## Algoritmo

Encontrar el valor de  $t$  que minimiza la varianza intra-clase

$$\sigma_w^2(t) = q_1(t)\sigma_1^2(t) + q_2(t)\sigma_2^2(t) \quad (2)$$

o maximizar la varianza entre-clases

$$\sigma_b^2(t) = q_1(t)(1 - q_2(t))(\mu_1(t) - \mu_2(t))^2 \quad (3)$$


	Class 1	Class 2
CDF <sup>a</sup>	$q_1(t) = \sum_{i=1}^t P(i)$	$q_2(t) = \sum_{i=t+1}^I P(i)$
Mean	$\mu_1(t) = \sum_{i=1}^t i \frac{P(i)}{q_1(t)}$	$\mu_2(t) = \sum_{i=t+1}^I i \frac{P(i)}{q_2(t)}$
Variance	$\sigma_1(t) = \sum_{i=1}^t (i - \mu_1(t))^2 \frac{P(i)}{q_1(t)}$	$\sigma_2(t) = \sum_{i=t+1}^I (i - \mu_2(t))^2 \frac{P(i)}{q_2(t)}$

---

<sup>a</sup>Cumulative Density Function


# Método de Rosin

En los casos en que el número de píxeles en las clases esté muy desequilibrado (1: 100 o incluso más)




## Algoritmo


- ❑ Dibuja una línea desde el histograma máximo hasta el final de la cola.
- ❑ Calcule la distancia de la línea a la curva del histograma.
- ❑ Seleccione el umbral a la distancia máxima.




# Ejemplo




Original image



Histogram



Threshold by Otsu



Threshold by Rosin


# Contenido

- 1 Definiendo la segmentación
- 2 Segmentación basada en información de vecindad
- 3 Segmentación utilizando probabilidades
- 4 Segmentación multi-clase

# Motivación

Un problema con los datos SNR bajos es la cantidad de píxeles clasificados incorrectamente

- ❑ Las distribuciones de intensidad se superponen.
- ❑ Es difícil encontrar un solo umbral.




## Solución








Introducir crecimiento de regiones (region growing) en el proceso de umbralizado.

# Region growing

- ❑ **Principio:** El crecimiento de la región comienza a partir de un pixel o región determinados. La región crece hasta:
  - Se alcanza una intensidad umbral absoluta.
  - La diferencia de intensidad alcanza un valor umbral.
  - Se supera una distancia, normalmente combinada con umbrales de intensidad.
- ❑ Esto se hace mediante:
  - Teniendo en cuenta el vecindario de píxeles.
  - Tanto sin supervisión como supervisada.
  - No debe basarse necesariamente en un histograma.



# Variaciones del region growing






# Umbralizado con histéresis

- ❑ Es difícil clasificar datos con distribuciones de clases superpuestas
- ❑ Un solo umbral de datos por debajo o por encima de los segmentos
- ❑ Combine dos umbrales con region growing
  - Establecer umbral alto como semilla
  - Realice el crecimiento de la región hasta el umbral más bajo.

## Ejemplo




# Umbral basado en histéresis: Método de Vogel

## Algoritmo

Calcular  $\hat{x} = \{x | h(x) = H(\min)\}$ , donde  $h(x)$  es una Gaussiana ajustada a la parte superior del histograma  $H(x)$

Encontrar los umbrales:  $t_{\min} = 0.5(\max_1 + \min)$  y  $t_{\max} = 0.5(\min + \hat{x})$

Umbral en dos pasos




# Contenido

- 1 Definiendo la segmentación
- 2 Segmentación basada en información de vecindad
- 3 Segmentación utilizando probabilidades
- 4 Segmentación multi-clase

# El umbral Neyman-Pearson

El umbral  $\eta$  es determinado a partir de la elección de valores para:

- **Probabilidad de falsa alarma:**  $P_F = P\{t(x) \geq \gamma | H_0\}$
- **Probabilidad de detección:**  $P_D = P\{t(x) \geq \gamma | H_1\}$



# Contenido

- 1 Definiendo la segmentación
- 2 Segmentación basada en información de vecindad
- 3 Segmentación utilizando probabilidades
- 4 Segmentación multi-clase


# Segmentación multi-clase



(a) Ground truth of CT image



(b) Learning rate  $\mu = 0.001$



(c) Learning rate  $\mu = 0.01$



(d) Ground truth of 3D rendering



(e) Learning rate  $\mu = 0.001$



(f) Learning rate  $\mu = 0.01$

# Extendiendo los métodos conocidos para multi-clase

- ❑ La segmentación multi-clase requiere más umbrales
- ❑ Mayor número de comparaciones
- ❑ Pueden ocurrir asignaciones ambiguas


## Otsu thresholding

Otsu previó la segmentación de múltiples clases (**Consultar Otsu method for multi-class segmentation**).

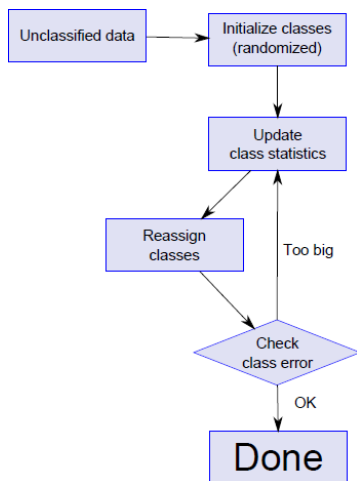
# Clasificación no supervisada: Fuzzy C Means

## Algunas características

- ❑ Datos multi-clase
- ❑ Métodos iterativos
- ❑ Operaciones basadas en pixel
- ❑ Optimización global
- ❑ No supervisada







## Algoritmo






# Problemas con la segmentación multi-fase

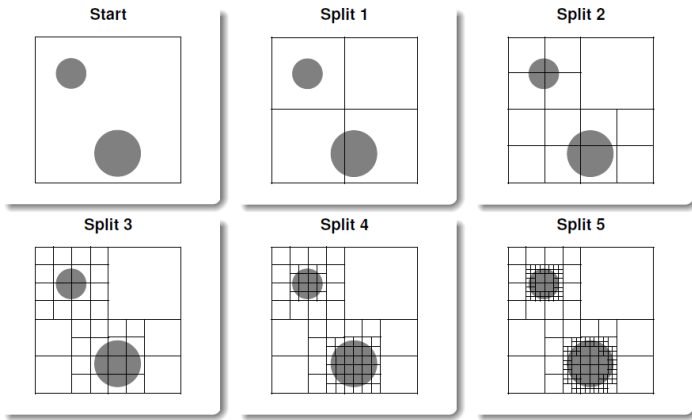


# Miremos más de cerca un borde





# Quad trees

Proceso iterativo para dividir en regiones cuando ellas no cumplen alguna dirección.





# Descomposición *Quad tree*



# Diferentes escalas

Trabaja con múltiples resoluciones



Propósito<sup>1</sup>:

- ❑ Menos sensible al ruido
- ❑ Mas rápido el procesamiento

---

<sup>1</sup>Burt's segmentation [1]

# Métodos basados en clasificación

## Data

- Imágenes de  $M$  modalidades

## Clases


Las  $N$  clases se describen mediante

- $H_1 : p(\mu_1, \sigma_1)$
- $H_2 : p(\mu_2, \sigma_2)$
- ...
- $H_N : p(\mu_N, \sigma_N)$

## Opciones

- Distancia Euclídea más pequeña (distancia de clase - media muestral)
- Distancias de clase multivariadas (Media y Covarianza)
- Machine Learning

# ML image segmentation



# Bibliography



Rafael C. Gonzalez and Richard E. Woods.

*Digital image processing.*

Prentice Hall, Upper Saddle River, N.J., 2008.